

---

# Introdução a Redes Neurais Artificiais

— Grupo de Estudos em Ciências  
de Dados —

---

# Roteiro

## Redes Neurais Artificiais (RNAs)


- Origens
- Aprendizagem em RNA
- Perceptron
- MLP

# Origens

- Funcionamento do cérebro;
  - Estrutura do neurônio real;
  - Comportamento do neurônio;
- Neurônio:
  - Corpo celular;
  - Prolongamento celulares finos (dendritos e axônio);

# Origens


- Dendritos:
  - São estruturas tubulares que se ramificam ao redor do corpo celular;
  - Superfície física pela qual um neurônio recebe sinais de outras células;



Fonte: PAIVA, Anabelle Barroso de/CEFET/SC

# Origens


- Corpo Celular:
  - Onde está localizado o núcleo;
  - Também recebe sinais de entrada;
  - Todos sinais que chegam ao neurônio são “processados” no corpo celular.



Fonte: PAIVA, Anabelle Baroso de/CEFET/SC

# Origens


- Axônio:
  - É uma linha de transmissão do neurônio;
  - Um extensão do corpo pela qual os sinais gerados trafegam por longas distâncias.



Fonte: PAIVA, Anabelle Baroso de/CEFET/SC


# Origens

- Sinapses:
  - Pontos de contato nos quais a informação é transferida de uma célula para outra;
  - Geralmente ocorrem entre axônio e dendrito;



# Origens


- Sinapses:
  - As sinapses nervosas são impulsos nervosos que passam de um neurônio para outro por meio de mediadores químicos, os neurotransmissores.






# Origens

- Sinapses:
  - Processo de transformação de um sinal elétrico em um sinal químico, e deste sinal químico de volta em um sinal elétrico;



# Origens



# Aprendizagem em RNA

- Habilidade de executar tarefas que não podiam ser executadas anteriormente;
- Melhorar a execução de tarefas que eram executadas antes;
- Uma RNA aprende através de um processo de ajuste de seus parâmetros:
  - Em geral, ajuste dos pesos sinápticos;

# Aprendizagem em RNA

- Considerando que uma rede neural está imersa em um ambiente, seu processo de aprendizagem compreende três premissas:
  - A rede neural é estimulada pelo ambiente;
  - Os estímulos induzem a modificação dos parâmetros livres da rede;
  - A resposta da rede está relacionada com sua **estrutura interna**. Esta estrutura é modificada de acordo com os estímulos recebidos pela rede.

# Aprendizagem em RNA

- Os processos de aprendizagem em redes neurais se baseiam em regras, entre elas se destacam:
  - **A regra de correção de erros;**
  - Regra de competição;

# Aprendizagem em RNA

- Regra de correção de erros:
  - Considerando que a resposta da rede (**y**) ocorre devido a ativação de um grupo sináptico (**w**) gerando um erro (**e**) a partir da entrada (**x**).
  - O erro é calculado com a diferença entre o valor desejado (**d**) e o valor da resposta obtida (**y**):


$$e = d - y$$

# Aprendizagem em RNA

- Regra de correção de erros:
  - O valor do erro muda de acordo com a entrada;
  - A regra de adaptação dos pesos modifica os pesos sinápticos de modo a diminuir o erro à medida que a regra vai sendo aplicada a cada novo estímulo.

# Perceptron


- O perceptron foi o primeiro modelo de rede neural artificial com capacidade de aprender;
- Sua arquitetura inicial consiste de:
  - Uma camada de entrada (X);
  - Uma camada de saída (Output);
  - Um conjunto de pesos (W) ligando a entrada à saída.






# Perceptron

- As entradas  $x_i$ ,  $i = 1, 2, \dots, n$ , são binárias;
- Os pesos  $w_i$  são números reais;
- Um estímulo  $X$  (padrão de entrada) é apresentado a rede gerando uma resposta na saída da rede através de uma regra de propagação:



# Perceptron

- Função de ativação:
  - Transforma um valor real obtido com a soma ponderada entre a entrada e os pesos da rede em um valor máximo ou mínimo;
- Exemplo: função sinal (utiliza um limiar);




# Perceptron

- Todo conhecimento da rede está codificado nos pesos.
- A aprendizagem ocorre através da modificação dos pesos da rede.
- Uma regra para atualizar os pesos:
  - $\Delta w_{ij} = \eta x_i (d_j - y_j)$
  - $\eta$  é a taxa de aprendizagem;
  - $d_j$  é o valor desejado para uma dado estímulo de entrada ( $x_i$ );


# Multilayer Perceptron - MLP

- O perceptron é uma rede simples;
  - Não é capaz de classificar padrões em classes que não são linearmente separáveis;
  - Não é possível traçar uma reta no plano capaz de separar as duas classes;
  - As limitações do perceptron impulsionaram o surgimento da rede MLP;




# Multilayer Perceptron - MLP

- A arquitetura da MLP consiste em:
  - Uma camada de entrada (X);
  - Uma ou mais camadas escondidas;
  - Uma camada de saída (y);




# Multilayer Perceptron - MLP

- A arquitetura da MLP consiste em:




# Multilayer Perceptron - MLP

- Funcionamento:
  - Um estímulo, sinal de entrada, é propagado da entrada para saída passando por cada camada escondida;
- Três características importante:
  - Cada neurônio na rede possui função de ativação;
  - Existe pelo menos uma camada escondida que possibilita aprendizagem de tarefas complexas;
  - Alto grau de conectividade;



# Multilayer Perceptron - MLP

- Fase para frente:
  - Entrada é apresentada à primeira camada da rede
    - Após os neurônios da camada  $i$  calcularem seus sinais de saída, os neurônios da camada  $i + 1$  calculam seus sinais de saída usando como entrada a saída dos neurônios da camada  $i$ ;





# Multilayer Perceptron - MLP

- Fase para frente (forward):
  - Saídas produzidas pelos neurônios da última camada são comparadas às saídas desejadas;
  - Erro para cada neurônio da camada de saída é calculado;

# Multilayer Perceptron - MLP

- Fase para trás (backward):
  - A partir da última camada:
    - Cada neurônio ajustar seus pesos de modo a reduzir o seu erro;
  - Neurônios das camadas anteriores tem seu erro definidos por:
    - Erros dos neurônios da camada seguinte conectados a ele ponderados pelos pesos das conexões entre eles;
  - Mais detalhes estuda a partir da página 175 do livro AI - A Guide to Intelligent Systems.

# Multilayer Perceptron - MLP

- Pontos Negativos da MLP
  - O conhecimento aprendido na MLP não é representado diretamente nos pesos. A rede é vista como uma caixa preta;
  - Ausência de uma abordagem bem fundamentada para avaliar o método de aprendizagem;
  - A generalização não é garantida, pode ocorrer sobreajuste (overfitting): a rede aprende muito bem os padrões de treinamento, mas não garante respostas acuradas para padrões não treinandos.

# Multilayer Perceptron - MLP

- Pontos Positivos da MLP
  - O usuário não precisa ter conhecimento significativo sobre o problema tratado;
  - Tolerância a dados de treinamento ruidosos ou faltosos;
  - Algoritmo de modelagem e treinamento não é complexo;
  - Boa capacidade de generalização com padrões não treinados.

# Tensor Flow

Funcionamento de uma rede neural ao vivo :)

- Tensor Flow, <https://playground.tensorflow.org>



Epoch  
000,000

Learning rate  
0.03

Activation  
Tanh

Regularization  
None

Regularization rate  
0

Problem type  
Classification

## DATA

Which dataset do you want to use?



Ratio of training to test data: 50%

Noise: 0

Batch size: 10

REGENERATE

## FEATURES

Which properties do you want to feed in?

$X_1$   
 $X_2$   
 $X_1^2$   
 $X_2^2$   
 $X_1X_2$   
 $\sin(X_1)$   
 $\sin(X_2)$


+ - 2 HIDDEN LAYERS

+ -

4 neurons

+ -


2 neurons




## OUTPUT

Test loss 0.527

Training loss 0.512



Colors shows data, neuron and weight values.




☐ Show test data

☐ Discretize output

# Referências

- Algumas figuras foram obtidas com pesquisas no buscador do google.

# Referências



GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems.** O'REILLY, 2017.




# Referências




MITCHELL; Machine Learning, Publisher:  
McGraw-Hill Science/Engineering/Math, 1997

# Referências



NEGNEVITSKY; Artificial Intelligence: A Guide to Intelligent Systems, Second Edition, Publisher Addison Wesley.

# Referências



HAYKIN; Neural Networks and Learning Machines (3rd Edition), Publisher: Pearson.

RUSSELL, STUART; NORVIG, PETER; Inteligência Artificial, 3. edição, Prentice Hall.

BRAGA; CARVALHO; e LUDERMIR; Redes neurais artificiais: teoria e aplicações, 2007

# Referências

- Página web com lições sobre TensorFlow, <https://learningtensorflow.com/>
- Pacote para machine learning em python, <http://scikit-learn.org>